기계학습기초 팀 프로젝트 최종 보고서

도서관 빅데이터 기반 미래 대출 수요 예측 AI 시스템

오한택 , 피윤아

Team 8

제출일: 2026년 6월 12일

https://github.com/2026-1st/team8

Abstract

본 연구는 도서관정보나루 공개 API 기반의 도서 대출 데이터를 활용하여 다음 달 도서 대출 수요를 예측하는 머신러닝 파이프라인을 설계하고 실험한다. 핵심 기여는 TF-IDF × TextRank 기반 트렌드 키워드 유사도 피처를 설계하여 사회적 트렌드와 도서 내용의 관련성을 수치화한 것이다. 2023~2025년 3개년 데이터를 수집하여 총 104,572행, 62개 피처의 데이터셋을 구축하였으며, 시간 기반 데이터 분할로 누수를 방지하였다. Lag 피처만 사용한 모델 A와 전체 피처를 사용한 모델 B를 비교한 결과, 모델 B의 XGBoost가 Validation R^2=0.9600, Test R^2=0.9297로 최고 성능을 달성하였다. 나이브 Baseline 대비 MAE를 55.1건에서 41.9건으로 13.2건 개선하였으며, MLP 딥러닝 실험에서는 R^2=0.9049를 달성하였다.

Keywords: 도서 대출 수요 예측, TF-IDF, TextRank, XGBoost, MLP, 시계열 Lag 피처, 피처 엔지니어링

목 차

1. Introduction ····· 4
1.1 연구 배경 및 필요성 ····· 4
1.2 해결 과제 정의 ····· 4
1.3 프로젝트 목표 및 기여 ····· 4
2. Related Work ····· 5
2.1 도서 추천 및 수요 예측 선행 연구 ····· 5
2.2 키워드 추출 및 트렌드 분석 ····· 5
2.3 기존 방법과 본 프로젝트의 차이점 ····· 5
3. Approach ····· 6
3.1 전체 파이프라인 ····· 6
3.2 데이터 수집 ····· 6
3.3 피처 엔지니어링 ····· 7
3.4 모델 및 알고리즘 ····· 9
4. Experiment ····· 10
4.1 데이터셋 설명 ····· 10
4.2 실험 환경 및 설정 ····· 10
4.3 데이터 분할 전략 ····· 11
4.4 평가 지표 정의 ····· 11
5. Results ····· 12
5.1 나이브 Baseline 비교 ····· 12
5.2 모델 A vs 모델 B (Validation) ····· 12
5.3 XGBoost 하이퍼파라미터 튜닝 ····· 13
5.4 최종 Test 셋 평가 ····· 14
5.5 MLP 딥러닝 실험 결과 ····· 15
6. Analysis / Discussion ····· 17
6.1 Feature Importance 분석 ····· 17
6.2 과적합 분석 ····· 18
6.3 결과 해석 및 핵심 결론 ····· 19
6.4 한계점 및 개선 방향 ····· 20
7. Conclusion ····· 21
7.1 전체 요약 ····· 19
7.2 모델별 의미 요약 ····· 19
7.3 예측 가능성 및 실용적 의미 ····· 19
7.4 윤리·공정성 논의 ····· 20
7.5 기대 효과 및 향후 확장 ····· 21
References ····· 23

1. Introduction

1.1 연구 배경 및 필요성

공공 도서관은 매달 수백만 건의 도서 대출이 발생하는 대규모 데이터 생산 기관이다. 그러나 대부분의 도서관 시스템은 단순히 현재 인기 도서를 보여주는 방식으로 운영되며, 과거 데이터를 기반으로 미래 수요를 예측하는 데이터 중심 의사결정 시스템은 부재한 상태이다.

현재 방식의 구조적 한계는 다음과 같다.

- 미래 트렌드 반영 불가 — 현재 인기 있는 책만 보여주며, 앞으로 뜰 가능성이 있는 책을 사전에 탐지하지 못함
- 급상승 도서 사전 감지 불가 — 순위가 빠르게 오르는 도서를 조기에 발견하지 못해 입고·추천 대응이 늦어짐
- 시간 패턴 미반영 — 방학 시즌 소설 수요 급증, 시험기간 전공서 수요 급증 등의 패턴을 인식하지 못함
- 이용자 인구통계 미활용 — 연령대·성별 등 이용자 특성에 따른 수요 차이를 분석하지 못함
- 트렌드 키워드-도서 관련성 미분석 — 사회적 이슈가 특정 도서 수요에 미치는 영향을 정량화하지 못함

1.2 해결 과제 정의

본 프로젝트는 다음 질문에 답하는 것을 핵심 과제로 정의한다.

> *Q1. 도서의 과거 대출 이력, 이용자 인구통계, 그리고 TF-IDF × TextRank 기반 트렌드 키워드 유사도를 결합하여 다음 달의 도서 대출 수요를 예측할 수 있는가?*
>
> *Q2. 트렌드 피처는 단순 Lag 피처 대비 실질적 성능 향상을 가져오는가?"*

1.3 프로젝트 목표 및 기여

- 자동 데이터 수집 파이프라인 구축 — 도서관정보나루 API 기반 3 개년 데이터 수집, usageAnalysisList 재수집으로 유효 ISBN 66 개 → 1,030 개 확대
- TF-IDF × TextRank 트렌드 피처 설계 — 도서 키워드와 이달의 트렌드 키워드 유사도를 수치화하는 새로운 피처 제안
- PoC 실험 설계 — Lag-only 모델(A) vs 전체 피처 모델(B) 비교로 피처 유효성 검증
- 나이브 Baseline 비교 체계 — R^2만으로는 모델 기여를 과장할 수 있으므로 나이브 대비 MAE 개선량을 함께 제시
- 딥러닝 MLP 추가 실험 — TensorFlow + Google Colab 환경에서 MLP(256→128→64→1) 구현

2. Related Work

2.1 도서 추천 및 수요 예측 선행 연구

도서 추천 시스템 분야에서 가장 널리 사용되는 방법은 협업 필터링이다. Koren et al.(2009)[1]은 Matrix Factorization 기법을 통해 이용자-아이템 상호작용 행렬을 저차원으로 분해하여 추천 정확도를 높였다. 그러나 이 방법은 현재 이용자 선호도를 기반으로 하며, 미래 시점의 수요 변화를 예측하는 데는 적합하지 않다.

시계열 수요 예측 관점에서 Makridakis et al.(2018)[2]은 통계 모델과 머신러닝 모델을 광범위하게 비교하였다. 단순 Lag 피처 기반 접근법이 복잡한 통계 모델과 비교하여 경쟁력 있는 성능을 보임을 입증하였으며, 이는 본 프로젝트의 모델 A 설계의 이론적 근거가 된다.

도서관정보나루 빅데이터 분석 공모전 우수작(2023)[6]에서는 동일한 데이터 소스를 활용하여 계절성과 대출 Lag 패턴이 도서 수요 예측에 유효함을 보였다. 그러나 NLP 기반 트렌드 피처를 활용하지 않았다는 점에서 본 프로젝트와 차별화된다.

2.2 키워드 추출 및 트렌드 분석 (TextRank & TF-IDF)

TextRank는 Mihalcea & Tarau(2004)[4]가 제안한 그래프 기반 키워드 추출 알고리즘이다. 텍스트 내 단어 간의 공기(Co-occurrence) 관계를 그래프로 모델링하고, PageRank 알고리즘을 적용하여 중요 키워드에 높은 가중치를 부여한다. 기존 연구에서는 주로 뉴스 기사나 논문 요약 등의 텍스트 문서에서 핵심 내용을 추출하는 데 활용되었다. 본 프로젝트에서는 이를 도서관정보나루 API에서 제공하는 도서 키워드 데이터에 적용하여, 각 도서의 핵심 키워드와 그 중요도(가중치)를 추출하였다.

TF-IDF는 Salton & Buckley(1988)[5]가 제안한 단어 중요도 계산 방법으로, 특정 문서에서 자주 등장하지만 전체 문서 집합에서는 드문 단어에 높은 가중치를 부여한다. 기존에는 주로 문서 검색, 텍스트 분류 등에서 단어 벡터를 만드는 데 사용되었다. 본 프로젝트에서는 이달의 트렌드 키워드 목록에 TF-IDF 방식을 적용하여 각 키워드의 사회적 중요도를 수치화하였다.

두 방법을 결합한 핵심 아이디어는 **3.3 피처 엔지니어링**에서 자세히 다루며, 기존 연구에서 별도로 사용되던 TextRank와 TF-IDF를 교차 곱셈(Cross Product) 방식으로 결합하여 도서와 트렌드 간의 관련성을 하나의 수치로 표현한 것이 본 프로젝트의 독창적 기여이다.

2.3 기존 방법과 본 프로젝트의 차이점

비교 항목	기존 방법	본 프로젝트
예측 방향	현재 인기 도서 기반 추천	미래(다음 달) 대출 수요 예측
트렌드 반영	불가	TF-IDF × TextRank 유사도 피처 활용
인구통계 활용	일부 CF 기반에서 간접 활용	연령대·성별 집계 통계 직접 피처화
평가 체계	Precision@K, NDCG	나이브 Baseline 대비 MAE 개선량 제시
딥러닝 비교	미포함	MLP 추가 실험으로 트리 기반 모델과 비교

3. Approach

3.1 전체 파이프라인

본 프로젝트의 전체 파이프라인은 5단계로 구성된다.

단계	모듈	입력	출력
1. 수집	dataset.py	도서관정보나루 API	8종 raw CSV
2. 전처리	process.py	raw CSV	104,572행 × 62 features
3. 학습	train.py	features_book.csv	모델 A vs B 비교
4. 튜닝	tune.py	features_book.csv	최적 파라미터
5. 평가	evaluate.py + review_experiments.py	학습된 모델	시각화, 나이브 비교

핵심 설계 원칙은 데이터 누수 방지이다. 모든 피처는 예측 대상 월 이전 시점의 데이터만 사용하며, 인코더·정규화 통계는 반드시 train 셋에서만 fit한다.

3.2 데이터 수집

도서관정보나루 공개 API를 통해 2023~2025년 3개년의 데이터를 수집하였다. API rate limit으로 인해 usageAnalysisList는 단계적으로 재수집하여 유효 ISBN을 66개에서 1,030개로 확대하였다.

수집 데이터	수집 규모	주요 컬럼
인기 대출 도서 (loanItemSrch)	180,000행 (월별 5,000건 × 36개월)	isbn13, 순위, 대출건수, 출판정보
이달의 키워드 (monthlyKeywords)	3,600행 (월별 100개 × 36개월)	keyword, weight
대출 급상승 도서 (hotTrend)	약 5,400행 (3일 단위)	isbn13, ranking_change
도서 이용 분석 (usageAnalysisList)	1,030 ISBN	대출이력, 키워드, 인구통계, co-loan

3.3 피처 엔지니어링

process.py에서 raw 데이터를 62개 피처로 변환한다.

(1) 시계열 Lag 피처 (20 개)

과거 6개월의 대출 건수와 순위 변화를 피처로 사용한다. window_size=6으로 설정하며, lag1이 직전달, lag6이 6달 전을 의미한다.

피처 그룹	주요 피처	개수

대출 시계열	loan_lag1~6, loan_mean, loan_max, loan_ma_3, loan_ma_6, loan_growth_1m	11개
순위 시계열	rank_lag1~6, rank_mean, rank_trend, rank_std	9개

(2) 도서 특성 피처 (40 개)

피처 그룹	주요 피처	개수
Hot Trend	hot_trend_recency, rank_gain_lag1/2, hot_trend_count	5개
도서 메타	bookname_length, book_age, kdc_class_enc, author_freq	6개
이용 통계	loanCnt_total, co_loan_count, co_loan_avg_pub_year 등	7개
인구통계	female_ratio, main_age_group_enc, age_group_count 등	6개
시리즈	has_vol, vol_num, series_size 등	5개
시간	month_num, season_enc, is_vacation, is_semester_start	4개
기타 NLP	keyword_count, keyword_weight_sum 등	4개

(3) 트렌드 NLP 피처 (2 개) — 핵심 제안

도서 대출 수요는 단순히 과거 패턴만으로는 설명되지 않는 경우가 있다. 예를 들어 특정 사회적 이슈가 부각되거나 미디어에서 특정 주제가 집중 조명될 때, 해당 주제와 관련된 도서의 대출 수요가 급증하는 현상이 나타난다. 기존의 Lag 피처는 이러한 트렌드 변화를 사전에 포착하지 못하고 이미 수요가 증가한 이후에야 반영할 수 있다는 한계가 있다. 이를 보완하기 위해 본 프로젝트에서는 도서의 내용과 사회적 트렌드 키워드 간의 유사도를 수치화하는 새로운 피처를 제안하였다.

구체적인 설계 방식은 다음과 같다. 도서관정보나루 API의 book_keywords 데이터에서 TextRank 기반으로 추출된 도서별 키워드와 그 가중치를 활용하고, 동일한 API의 monthlyKeywords 데이터에서 TF-IDF 방식으로 산출된 이달의 트렌드 키워드와 그 가중치를 활용한다. 두 키워드 집합에서 공통으로 등장하는 키워드를 찾고, 각 공통 키워드에 대해 도서 키워드 가중치와 트렌드 키워드 가중치를 곱한 뒤 합산하여 최종 유사도 점수를 계산한다.

계산 수식: keyword_trend_similarity = Σ(book_kw_weight_i × monthly_kw_weight_i), i ∈ 교집합 키워드

예시로 설명하면, 어떤 도서의 키워드가 [지구(0.8), 생명(0.6), 기후(0.5)]이고 전달 트렌드 키워드가 [생명(0.9), 사랑(0.7), 환경(0.6)]이라면, 공통 키워드는 "생명" 하나이므로 similarity = 0.6 × 0.9 = 0.54, overlap = 1이 된다. 이 값이 클수록 해당 도서의 내용이 최근 사회적 트렌드와 밀접하게 연관되어 있음을 의미하며, 모델은 이를 수요 증가의 신호로 학습하게 된다.

데이터 누수를 방지하기 위해 트렌드 키워드는 반드시 예측 대상 월의 전달(prev_yyyymm) 데이터를 사용한다. 예를 들어 2024년 3월의 대출 수요를 예측할 때는 2024년 2월의 트렌드 키워드를 사용한다. 이를 통해 미래 정보가 피처에 포함되는 것을 원천 차단하였다.

재수집 완료 후 keyword_trend_similarity의 non-zero 행은 전체 104,572행 중 13,056행(12.5%)이었다. 이는 전체 데이터의 약 1/8에 해당하는 도서가 당월 트렌드와 관련성을 가진다는 의미로, 트렌드 피처가 특정 도서 그룹의 수요 예측에 집중적으로 작용하는 구조임을 보여준다.

(4) 타겟 변수

변수명	범위	생성 방법	용도
demand_score	0 ~ 1	rank_gain×0.5 + loan_ratio×0.5 → MinMaxScaler	주 학습 타겟
aux_target_log1p	0 ~	np.log1p(다음달 실제 대출 건수)	나이브 baseline 비교용

※ demand_score는 log1p 변환값이 아닌 0~1 정규화 점수이다. 실제 대출 건수 역변환 시 반드시 aux_target_log1p에 np.expm1()을 적용해야 한다.

3.4 모델 및 알고리즘

모델	유형	선택 이유	주요 설정
Linear Regression	선형	Baseline — 가장 단순, 비선형 학습 불가	기본 설정
Random Forest	트리 앙상블	비선형 학습, Feature Importance 확인 가능	n_estimators=100, random_state=42
XGBoost	Gradient Boosting	표 형식 데이터 최강 성능[3], 튜닝 가능	최적: n_est=300, depth=4, lr=0.01, sub=0.7
MLP (딥러닝)	신경망	선택 과제 — TensorFlow + Colab 구현	256→128→64→1, EarlyStopping(patience=10)

(1) Linear Regression

Linear Regression은 입력 피처와 타겟 변수 사이의 선형 관계를 학습하는 가장 단순한 회귀 모델이다. 수식은 $\hat{y} = w_1x_1 + w_2x_2 + \dots + w_nx_n + b$로 표현되며, 학습 과정에서 실제값과 예측값의 차이(MSE)를 최소화하는 가중치 w를 찾는다.

본 프로젝트에서 Linear Regression을 포함한 이유는 두 가지이다. 첫째, Baseline 역할을 한다. 가장 단순한 모델의 성능을 먼저 확인함으로써, 복잡한 모델이 실제로 얼마나 추가적인 성능 향상을 가져오는지 비교 기준점을 설정할 수 있다. 둘째, 데이터의 선형성을 간접적으로 확인할 수 있다. 도서 대출 수요는 직전달 대출량(loan_lag1)과 강한 선형 관계를 가지므로, 선형 모델만으로도 높은 기준 성능이 확보된다.

다만 급상승 도서처럼 수요가 비선형적으로 급변하는 패턴이나, 여러 피처가 복잡하게 상호작용하는 구조는 선형 모델로는 포착하기 어렵다. 이 한계를 보완하기 위해 비선형 모델인 Random Forest와 XGBoost를 함께 실험하였다.

(2) Random Forest

Random Forest는 여러 개의 Decision Tree를 독립적으로 학습시키고 그 예측의 평균을 최종 출력으로 사용하는 앙상블 모델이다. 핵심 아이디어는 "다양한 트리들이 각자 조금씩 다른 시각으로 데이터를 보고, 그 결과를 평균 냄으로써 단일 트리보다 더 안정적인 예측을 만들어낸다"는 것이다.

구체적으로 각 트리는 전체 학습 데이터 중 무작위로 선택된 부분집합(Bootstrap Sampling)과, 전체 피처 중 무작위로 선택된 일부 피처만 사용하여 학습한다. 이 과정이 트리 간의 다양성을 만들어내고, 결과적으로 특정 패턴에 지나치게 맞춰지는 과적합을 방지한다.

본 프로젝트에서 Random Forest를 선택한 이유는 세 가지이다. 첫째, rank_lag1, loan_lag1처럼 강한 신호를 가진 피처와 female_ratio, co_loan_count처럼 보조적인 신호를 가진 피처가 복합적으로 작용하는 구조에서, 비선형 관계를 자연스럽게 학습할 수 있다. 둘째, 이상치나 결측치가 있는 데이터에 상대적으로 강인하다. 셋째, Feature

Importance 분석이 가능하여 어떤 피처가 예측에 얼마나 기여하는지를 직접 확인할 수 있어, 피처 유효성 검증에 유용하다.
본 실험에서 Random Forest는 n_estimators=100, random_state=42로 설정하였으며, Validation 기준 R^2 =0.9605로 머신러닝 모델 중 가장 높은 성능을 기록하였다.

(3) XGBoost

XGBoost(Extreme Gradient Boosting)는 Gradient Boosting 방식을 기반으로 하며, 이전 트리의 예측 오차(잔차)를 다음 트리가 순차적으로 보완하며 학습하는 모델이다. 핵심 아이디어는 "틀린 부분에 집중하여 반복적으로 개선"하는 것이다. Random Forest가 트리들을 병렬로 독립 학습시키는 것과 달리, XGBoost는 이전 트리의 실수를 다음 트리가 교정하는 순차적 구조를 가진다.
XGBoost가 표 형식(Tabular) 데이터에서 강력한 성능을 보이는 이유는, 오차 함수의 1차 미분(그라디언트)뿐 아니라 2차 미분(헤시안)까지 활용하여 각 트리를 더 정밀하게 최적화하기 때문이다. 또한 L1, L2 정규화가 내장되어 있어 과적합을 억제하면서도 복잡한 패턴을 학습할 수 있다.
본 프로젝트에서는 기본 설정(n_estimators=100, max_depth=6, learning_rate=0.3)에서 출발하여 4가지 조합의 하이퍼파라미터 튜닝을 진행하였다. 최적 파라미터인 n_estimators=300, max_depth=4, learning_rate=0.01, subsample=0.7의 의미는 다음과 같다. max_depth를 6에서 4로 줄인 것은 트리의 복잡도를 제한하여 과적합을 방지하기 위함이다. learning_rate를 0.3에서 0.01로 줄인 것은 각 트리가 오차를 보정하는 속도를 늦춰 더 정밀하게 학습하도록 유도한 것이다. subsample=0.7은 각 트리 학습 시 전체 데이터의 70%만 사용하여 다양성을 확보한다. 이 튜닝 결과 Validation R^2=0.9600, 최종 Test R^2=0.9297, 나이브 대비 MAE 13.2건 개선으로 머신러닝 모델 중 최고 성능을 달성하였다.

(4) MLP (Multi-Layer Perceptron)

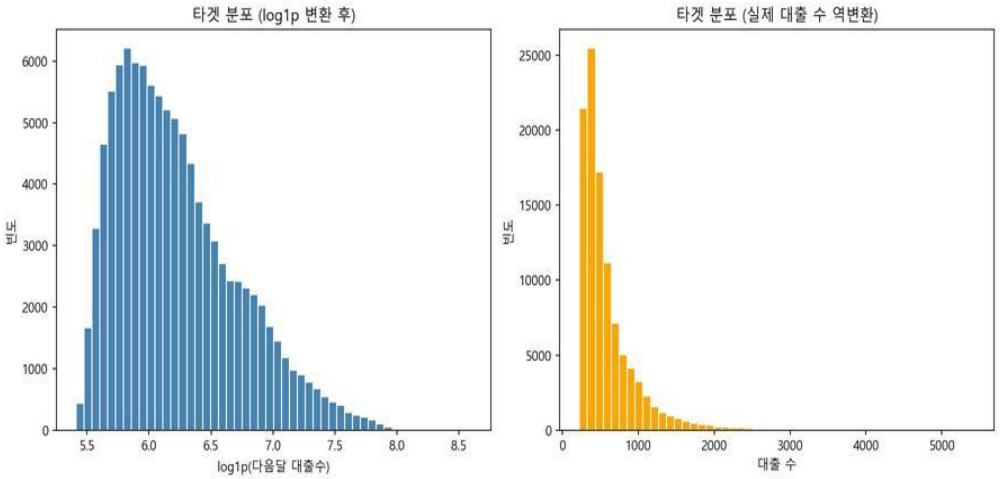
MLP는 입력층, 은닉층, 출력층으로 구성된 신경망 모델이다. 각 층의 뉴런은 이전 층의 모든 뉴런과 연결되어 있으며, 비선형 활성화 함수(ReLU)를 통해 복잡한 비선형 관계를 학습할 수 있다. 학습 과정에서 역전파(Backpropagation) 알고리즘으로 각 연결의 가중치를 반복적으로 조정한다.
본 프로젝트의 MLP 구조는 입력층(61개 피처) → Dense(256, ReLU) → BatchNormalization → Dropout(0.3) → Dense(128, ReLU) → BatchNormalization → Dropout(0.2) → Dense(64, ReLU) → Dense(1, 출력)으로 설계되었다. BatchNormalization은 각 층의 출력을 정규화하여 학습을 안정화시키고, Dropout은 학습 시 일부 뉴런을 무작위로 비활성화하여 과적합을 방지한다. 또한 MLP는 피처 스케일에 민감하므로 학습 전 StandardScaler로 모든 피처를 정규화하였다.
EarlyStopping(patience=10)을 적용하여 Validation Loss가 10 epoch 이상 개선되지 않으면 학습을 자동 중단하고 가장 성능이 좋았던 가중치를 복원하도록 설정하였다. 실제 학습은 15 epoch에서 조기 종료되었으며, 최종 Test R^2=0.9049를 기록하였다.
MLP가 XGBoost보다 낮은 성능을 보인 이유는 표 형식 데이터에서는 트리 기반 모델이 일반적으로 딥러닝보다 우수하다는 것이 선행 연구에서도 확인된 일반적인 경향이기 때문이다. 그럼에도 R^2=0.9049를 달성한 것은 딥러닝 구조가 이 예측 과제에 적용 가능함을 보여주는 의미 있는 결과이다.

4. Experiment

4.1 데이터셋 설명

항목	내용

전체 행 수	104,572행 (요구사항 1,000개 이상 충족)
피처 수	62개 (요구사항 10개 이상 충족)
타겟 변수	demand_score (0~1), aux_target_log1p (보조)
수집 기간	2023년 1월 ~ 2025년 12월 (36개월)
상세 API 커버리지	1,030 ISBN / 12,821개 (8.0%)
결측치	없음 (NaN 0개)



[그림 1] 타겟 분포. 왼쪽: aux_target_log1p 분포(log1p 변환으로 균등화됨). 오른쪽: 실제 대출 건수 분포(오른쪽 치우침). ※ demand_score(0~1)는 log 변환값이 아니므로 expm1 대상 아님.

위 그림은 본 프로젝트에서 예측하고자 하는 타겟 변수의 분포를 시각화한 것이다.

왼쪽(파란색) 그래프는 보조 타겟인 aux_target_log1p, 즉 다음 달 실제 대출 건수에 log1p 변환을 적용한 분포이다. x축의 값이 5.5~8.5 범위에 걸쳐 비교적 고르게 분포하고 있으며, 이는 log1p 변환이 오른쪽으로 치우친 원래 분포를 균등화하는 데 효과적임을 보여준다. 이처럼 변환된 값은 머신러닝 모델이 안정적으로 학습하는 데 유리하다.

오른쪽(주황색) 그래프는 aux_target_log1p에 np.expm1()을 적용하여 실제 대출 건수로 역변환한 분포이다. 대부분의 도서가 월 500건 미만의 대출을 기록하고 있으며, 1,000건을 넘는 도서는 극소수에 불과하다. 이는 소수의 인기 도서가 전체 대출의 대부분을 차지하는 도서관 대출 데이터의 전형적인 특성인 롱테일(Long-tail) 분포를 잘 보여준다.

여기서 주의해야 할 점이 있다. 주 타겟인 demand_score는 rank_gain과 loan_ratio를 결합하여 0~1 사이로 정규화한 점수로, log1p 변환값이 아니다. 따라서 demand_score에 np.expm1()을 적용하면 잘못된 값이 출력된다. 실제 대출 건수가 필요한 경우에는 반드시 aux_target_log1p에 np.expm1()을 적용해야 한다.

4.2 실험 환경 및 설정

환경 항목	ML 모델	MLP (딥러닝)
언어/버전	Python 3.10	Python 3.12 (Colab)

주요 라이브러리	scikit-learn 1.8.0, XGBoost 3.2.0	TensorFlow 2.x, Keras
실행 환경	Windows 11, VS Code	Google Colab (CPU)
난수 고정	random_state=42	tf.random.set_seed(42)
데이터 정규화	불필요 (트리 기반)	StandardScaler 적용

4.3 데이터 분할 전략

랜덤 분할 대신 시간 기반 분할을 사용하여 미래 데이터 누수를 원천 차단하였다. 인코더(LabelEncoder), 정규화(MinMaxScaler)는 train 셋에서만 fit()하고, validation/test에는 transform()만 적용한다.

시간 기반 분할을 선택한 이유는 본 과제의 본질적 특성 때문이다. 과거 데이터로 미래 수요를 예측하는 문제에서 랜덤 분할을 적용하면 미래 데이터로 과거를 예측하는 비현실적인 구조가 만들어질 수 있다. 시간 순서를 엄격히 준수함으로써 이 문제를 원천 차단하였다.

분할 비율을 80:10:10으로 설정한 이유는 모델이 계절성, 방학, 학기 시작 등 다양한 시간적 패턴을 충분히 학습하도록 Train 셋을 최대한 크게 유지하면서, Validation과 Test에도 의미 있는 규모의 데이터를 확보하기 위한 균형을 고려한 결정이다. Test 기간(202510~202603)은 2학기 시작부터 이듬해 초까지를 포함하여 학기 시작, 연말, 새학기 패턴이 모두 담겨 있어 모델의 일반화 성능을 다양한 시나리오에서 평가할 수 있도록 구성하였다.

Split	기간	행 수	비율	용도
Train	202301 ~ 202506	83,372행	79.7%	모델 학습 및 인코더·정규화 fit
Validation	202507 ~ 202509	10,475행	10.0%	하이퍼파라미터 튜닝 및 모델 선택
Test	202510 ~ 202603	10,725행	10.2%	최종 성능 평가 (단 1회 사용)

4.4 평가 지표 정의

지표	수식	선택 이유
MAE	$(1/n)\Sigma\|y_i-\hat{y}_i\|$	이상치에 덜 민감, 실제 대출 건수 오차를 직관적으로 해석 가능
RMSE	$\sqrt{((1/n)\Sigma(y_i-\hat{y}_i)^2)}$	큰 오차에 더 큰 패널티, 모델 비교 표준 지표
R^2	1-SS_res/SS_tot	전체 분산 중 모델이 설명하는 비율

※ R^2는 데이터의 강한 자기상관으로 인해 나이브 Baseline도 0.9224를 달성하므로, 모델 기여 평가는 반드시 나이브 대비 MAE 개선량을 함께 제시한다.

5. Results

5.1 나이브 Baseline 비교

머신러닝 모델의 성능을 평가할 때 단순히 R^2나 RMSE 수치만으로는 모델이 실제로 얼마나 유용한지 판단하기 어렵다. 특히 도서 대출 데이터처럼 월별 자기상관이 강한 데이터에서는 복잡한 모델을 사용하지 않아도 높은 R^2가 나올 수 있기 때문이다. 이를 명확히 하기 위해 나이브 Baseline을 기준점으로 설정하였다.

나이브 Baseline이란 어떠한 학습 과정도 없이 "지난달 대출 수 = 다음 달 대출 수"로 예측하는 가장 단순한 방법이다. 즉 모델이 아무것도 학습하지 않고 단순히 직전 값을 그대로 반복하는 전략이다. 이 방법이 의미 있는 기준점이 되는 이유는, 만약 머신러닝 모델이 이 단순한 방법보다 크게 낫지 않다면 복잡한 모델을 사용할 근거가 약해지기 때문이다.

실험 결과 나이브 Baseline만으로도 R^2=0.9224, MAE=55.1건이 달성되었다. 이는 도서 대출 데이터의 월별 자기상관이 매우 강하다는 것을 의미한다. 즉 이번 달 많이 빌린 책은 다음 달에도 많이 빌리는 패턴이 매우 뚜렷하다. 따라서 본 프로젝트에서는 R^2 수치 단독으로 모델 성능을 평가하지 않고, 나이브 Baseline 대비 MAE 개선량을 함께 제시하여 모델의 실질적 기여를 측정하였다. XGBoost tuned가 MAE를 55.1건에서 41.9건으로 13.2건 개선한 것은 단순 반복 예측을 넘어 실질적인 정확도 향상이 이루어졌음을 보여준다.

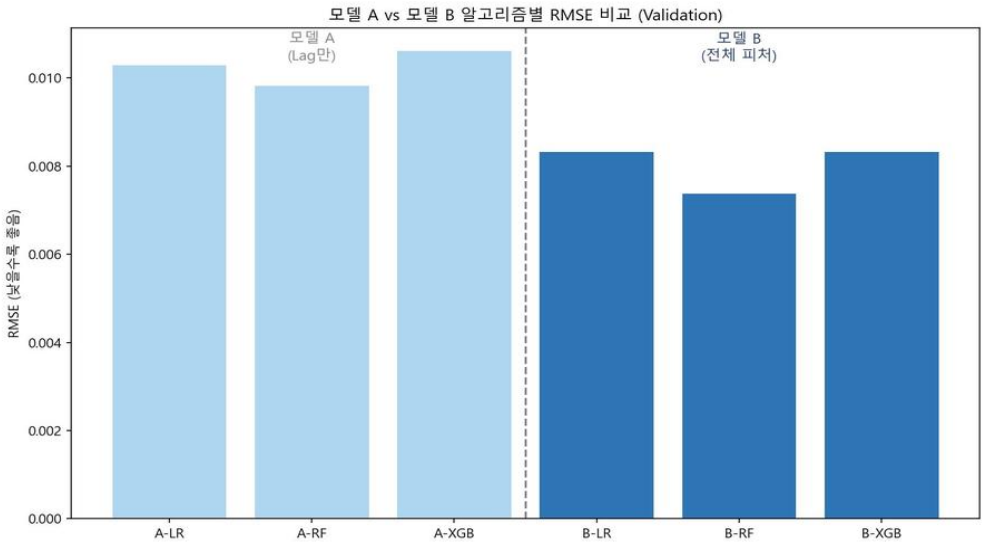
방법	R^2	MAE (건)	나이브 대비 개선
나이브 Baseline	0.9224	55.1건	기준선
LinearRegression (모델B)	0.9408	48.7건	-6.4건
RandomForest (모델B)	0.9446	46.6건	-8.5건
XGBoost tuned (모델B) ★	0.9492	41.9건	-13.2건 (최고)

5.2 모델 A vs 모델 B 비교 (Validation 셋)

동일한 3가지 알고리즘을 Lag 피처만 사용한 모델 A와 전체 62개 피처를 사용한 모델 B에 각각 적용하였다.

모델	알고리즘	MAE	RMSE	R^2
모델 A (Lag only)	Linear Regression	0.0071	0.0103	0.9231
모델 A (Lag only)	Random Forest	0.0064	0.0098	0.9299
모델 A (Lag only)	XGBoost	0.0065	0.0106	0.9182
모델 B (전체 피처)	Linear Regression	0.0052	0.0083	0.9497
모델 B (전체 피처)	Random Forest ★	0.0044	0.0074	0.9605
모델 B (전체 피처)	XGBoost	0.0047	0.0083	0.9496

모델 B가 모든 알고리즘에서 A보다 우수. Best RMSE: A(0.0098) → B(0.0074), 24.5% 향상. TF-IDF×TextRank 트렌드 피처의 유효성 PoC 검증 완료.



[그림 2] 모델 A vs 모델 B 알고리즘별 RMSE 비교 (Validation 셋). 연한색: 모델 A, 진한색: 모델 B. B 3개 모두 A보다 낮은 RMSE.

표와 그림 2 를 함께 살펴보면 몇 가지 중요한 패턴을 확인할 수 있다. 먼저 모델 A(Lag only)의 결과를 보면, Linear Regression(R^2=0.9231), Random Forest(R^2=0.9299), XGBoost(R^2=0.9182)로 세 알고리즘 모두 비슷한 수준의 성능을 보인다. 이는 Lag 피처만 사용하는 상황에서는 어떤 알고리즘을 쓰더라도 성능 차이가 크지 않음을 의미한다. 즉 lag/rank 피처가 제공하는 정보량 자체가 성능의 상한을 결정하고 있는 것이다.

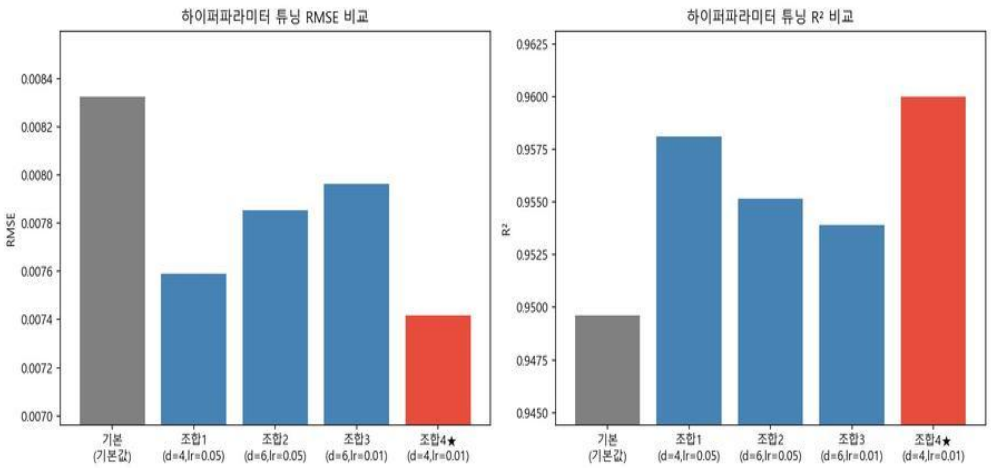
반면 전체 62 개 피처를 사용한 모델 B 에서는 알고리즘 간 성능 차이가 더 뚜렷해진다. Linear Regression 은 R^2=0.9497 로 모델 A 대비 개선되었지만, Random Forest(R^2=0.9605)와 XGBoost(R^2=0.9496)는 더 큰 폭으로 향상되었다. 이는 TF-IDF×TextRank 트렌드 유사도, 인구통계, co-loan 피처 등 추가된 피처들이 비선형적인 상호작용을 포함하고 있어, 이를 학습할 수 있는 트리 기반 모델에서 더 큰 성능 향상이 나타난 것으로 해석된다.

그림 2 에서 이 차이가 시각적으로 명확하게 드러난다. 연한 파란색 막대(모델 A)에 비해 진한 파란색 막대(모델 B)가 전체적으로 낮은 RMSE 를 기록하고 있으며, 특히 B-RF(Random Forest)가 0.0074 로 6 개 모델 중 가장 낮은 RMSE 를 달성하였다. Best RMSE 기준으로 모델 A 의 0.0098 에서 모델 B 의 0.0074 로 24.5% 향상되었으며, 이는 TF-IDF×TextRank 트렌드 피처를 포함한 전체 피처 구성이 예측 성능 향상에 실질적으로 기여하였음을 보여주는 PoC 검증 결과이다.

5.3 XGBoost 하이퍼파라미터 튜닝

기본 XGBoost 모델에서 출발하여 4가지 파라미터 조합을 수동으로 실험하였다. 조정한 핵심 파라미터는 max_depth, learning_rate, n_estimators, subsample이며, 각각의 역할은 다음과 같다. max_depth는 각 트리의 최대 깊이를 제한하여 모델의 복잡도를 조절한다. 값이 클수록 더 복잡한 패턴을 학습할 수 있지만 과적합 위험이 높아진다. learning_rate는 각 트리가 오차를 보정하는 속도를 조절한다. 값이 작을수록 천천히 정밀하게 학습하여 일반화 성능이 향상되는 경향이 있다. n_estimators는 사용할 트리의 총 개수이며, learning_rate를 낮추면 더 많은 트리가 필요하므로 함께 늘려주는 것이 일반적이다. subsample은 각 트리를 학습할 때 사용할 데이터의 비율로, 1.0 미만으로 설정하면 데이터 다양성이 확보되어 과적합을 방지한다.

조합	n_est	max_depth	lr	subsample	Val RMSE	Val R^2
기본	100	6	0.30	1.0	0.0083	0.9496
조합1	200	4	0.05	0.8	0.0076	0.9581
조합2	300	6	0.05	0.8	0.0079	0.9552
조합3	200	6	0.01	0.9	0.0080	0.9539
조합4★ 최적	300	4	0.01	0.7	0.0074	0.9600



[그림 3] XGBoost 하이퍼파라미터 튜닝 결과. 좌: RMSE, 우: R^2. 조합4★(d=4, lr=0.01)이 최적 달성.

표와 그림 3 을 통해 각 조합의 결과를 비교하면 몇 가지 패턴이 명확히 드러난다. 먼저 기본 모델(max_depth=6, lr=0.3)은 Val RMSE=0.0083 으로 가장 낮은 성능을 보였다. 조합 1(max_depth=4, lr=0.05)에서 RMSE 가 0.0076 으로 크게 개선되었는데, 이는 max_depth 를 6 에서 4 로 줄인 것만으로도 과적합이 줄어들고 일반화 성능이 향상됨을 보여준다. 조합 2 와 조합 3 을 비교하면 max_depth=6 보다 max_depth=4 가 일관되게 더 좋은 성능을 보이며, learning_rate 를 0.01 로 낮춘 경우 더욱 안정적인 결과를 나타낸다. 최종적으로 조합 4(n_estimators=300, max_depth=4, learning_rate=0.01, subsample=0.7)가 Val RMSE=0.0074, Val R^2=0.9600 으로 가장 우수한 성능을 달성하였다. 이는 트리 깊이 제한으로 복잡도를 줄이고, 낮은 학습률로 정밀하게 학습하며, 데이터 샘플링으로 다양성을 확보한 세 가지 전략이 함께 작용한 결과이다.

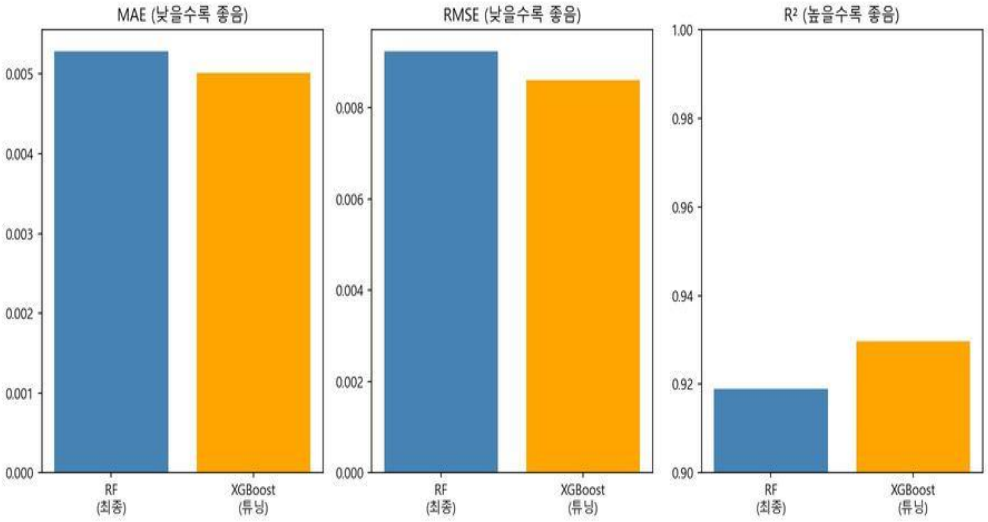
5.4 최종 Test 셋 평가

모든 모델 설계 완료 후 test 셋에 단 1회 평가하였다.

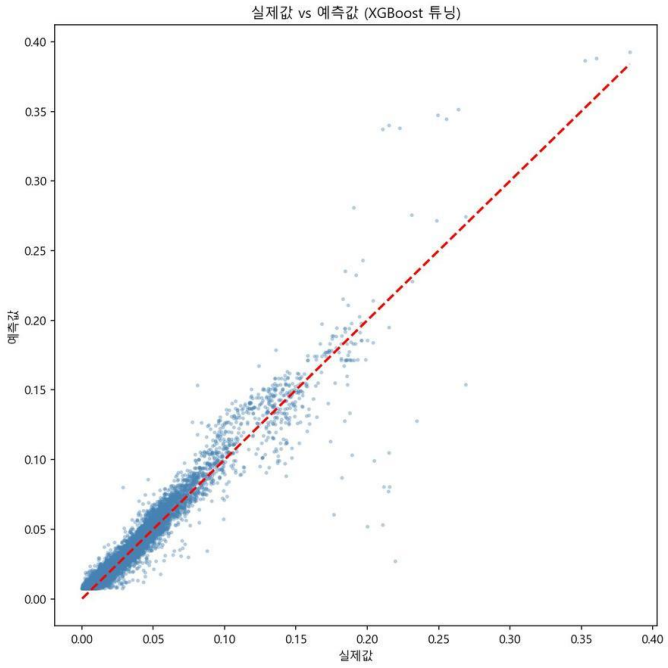
모델	MAE	RMSE	R^2
Random Forest (모델B)	0.0053	0.0092	0.9189
XGBoost 튜닝 (모델B) ★	0.0050	0.0086	0.9297

최종 Test 셋 평가 결과, XGBoost 튜닝 모델이 MAE=0.0050, RMSE=0.0086, R^2=0.9297로 Random Forest(MAE=0.0053, RMSE=0.0092, R^2=0.9189)보다 모든 지표에서 우수한 성능을 기록하였다. 두 모델의 차이가 크지 않은 이유는 둘 다 동일한 62개 피처를 사용하는 모델 B이기 때문이며, XGBoost가 하이퍼파라미터 튜닝을 통해 추가적인 성능 향상을 이끌어낸 결과이다.

그림 4를 보면 MAE와 RMSE에서는 XGBoost(주황색)가 RF(파란색)보다 낮고, R^2에서는 더 높게 나타난다. 세 지표 모두에서 XGBoost가 우위를 보이는 것은 단순히 하나의 지표에서만 좋은 것이 아니라 전반적인 예측 품질이 더 높음을 의미한다.



[그림 4] 최종 모델 비교 (Test 셋). XGBoost 튜닝이 모든 지표에서 RF보다 소폭 우수.



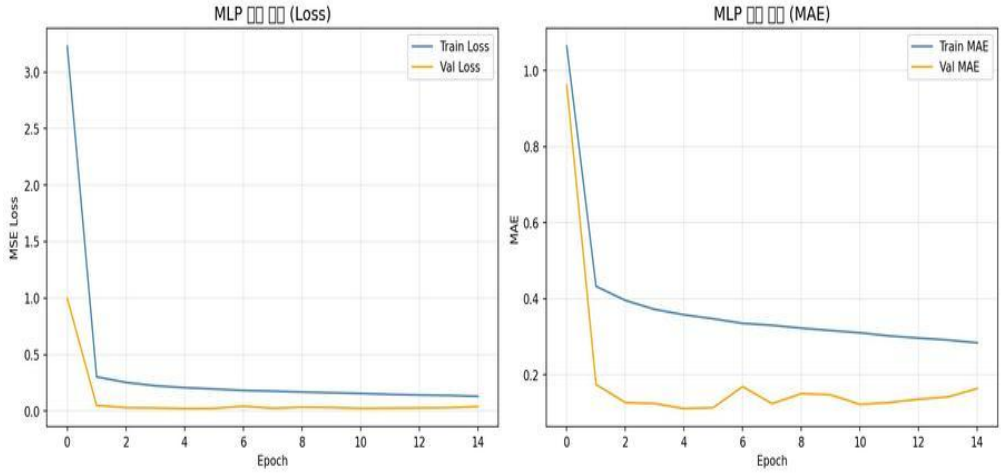
[그림 5] 실제값 vs 예측값 산점도 (XGBoost 튜닝, Test 셋). 대각선 근처에 밀집, 고대출 구간에서 일부 과소 예측.

그림 5 의 산점도에서 대부분의 점이 빨간 대각선 근처에 밀집되어 전반적으로 높은 예측 정확도를 보인다. 저대출 구간(0.05 이하)에서는 예측값과 실제값이 매우 일치하는 반면, 고대출 구간(0.2 이상)에서는 대각선에서 벗어나는 과소 예측 경향이 나타난다. 이는 급상승 도서처럼 수요가 갑작스럽게 증가하는 비선형 패턴을 모델이 완전히 포착하지 못한 것으로 해석된다.

5.5 MLP 딥러닝 실험 결과

TensorFlow + Google Colab 환경에서 MLP를 구현하고 동일 데이터셋으로 실험하였다.

설정	값
구조	Input(61) → Dense(256,ReLU) → BN → Dropout(0.3) → Dense(128,ReLU) → BN → Dropout(0.2) → Dense(64,ReLU) → Dense(1)
총 파라미터	58,625개
Optimizer	Adam (lr=0.001)
EarlyStopping	patience=10, monitor=val_loss, restore_best_weights=True
실제 학습 Epoch	15 epoch (EarlyStopping 동작)
정규화	StandardScaler (MLP는 피처 스케일에 민감)



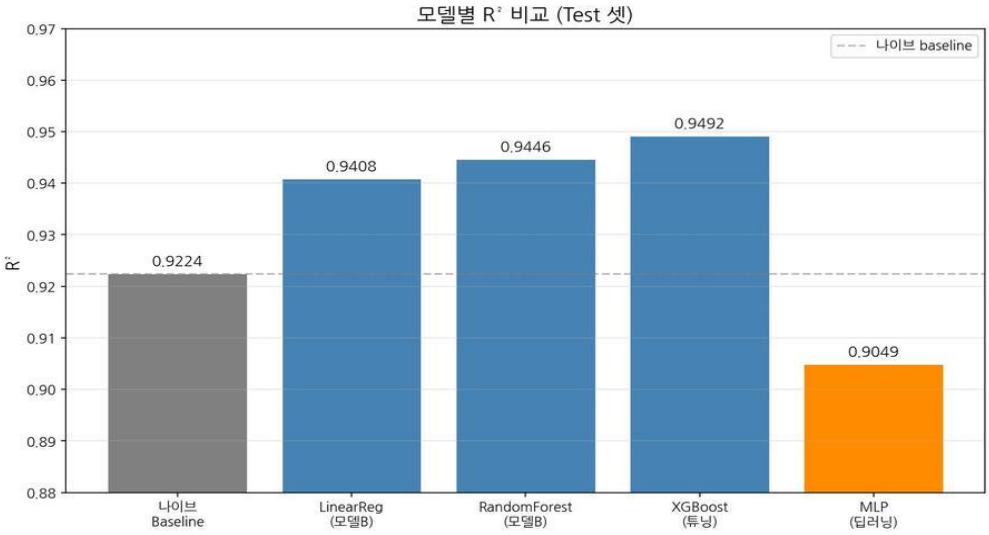
[그림 6] MLP 학습 곡선. 좌: Loss, 우: MAE. Train/Val 빠르게 수렴, 과적합 없음. 15 epoch에서 EarlyStopping 동작.

그림 6의 학습 곡선에서 Train Loss(파란선)와 Validation Loss(주황선) 모두 epoch 1~2 구간에서 급격히 감소한 뒤 빠르게 수렴하는 패턴을 보인다. 두 곡선이 크게 벌어지지 않고 함께 수렴하고 있어 과적합이 발생하지 않았음을 확인할 수 있다. MAE 곡선에서도 Validation MAE가 Train MAE보다 낮게 유지되는 구간이 있는데, 이는 Dropout과 BatchNormalization이 정규화 효과를 발휘하고 있음을 나타낸다. EarlyStopping이 15 epoch에서 동작하여 학습을 조기 종료하고 가장 성능이 좋았던 가중치를 복원하였다.

모델	R^2	MAE	RMSE
나이브 Baseline	0.9224	-	-
XGBoost tuned (ML 최고)	0.9492	0.0050	0.0086
MLP 딥러닝	0.9049	0.1132	0.1466

성능 비교 표를 보면 MLP(R^2=0.9049)가 XGBoost tuned(R^2=0.9492)보다 낮고, 나이브 Baseline(R^2=0.9224)보다도 낮은 결과를 보였다. 이는 표 형식 데이터에서 트리 기반 모델이 딥러닝보다 일반적으로 우수하다는 선행 연구의 결과와 일치한다. 또한 MLP의 MAE=0.1132는 XGBoost의 0.0050에 비해 상당히 높은데, 이는 MLP가 demand_score 단위의 피처 스케일을 StandardScaler로 정규화하였음에도 트리 기반 모델만큼

정밀한 예측에는 이르지 못하였음을 보여준다.

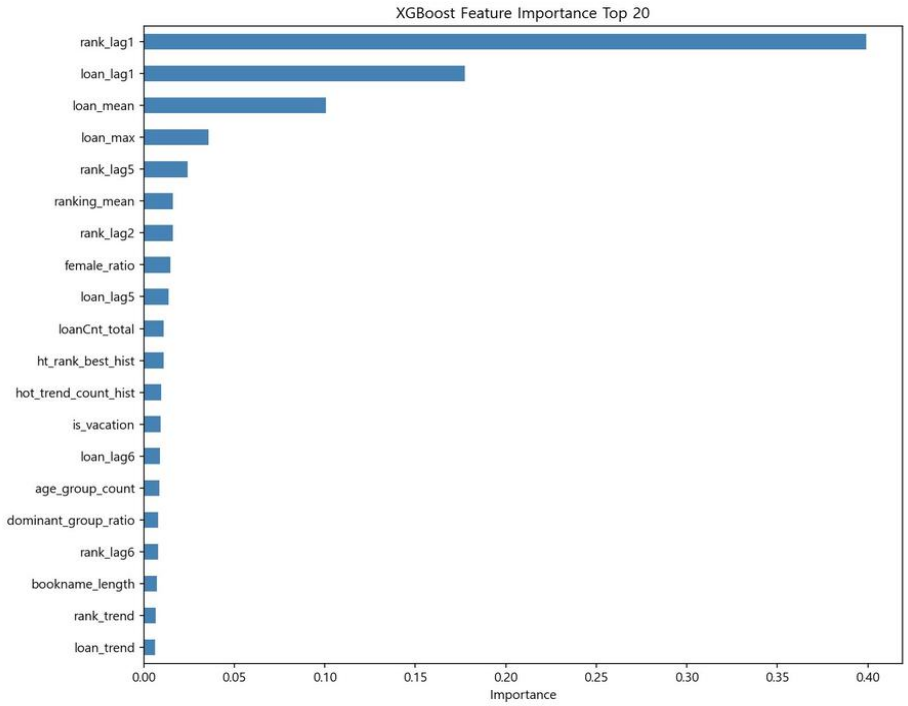


[그림 7] 전체 모델 R² 비교 (Test 셋). XGBoost(0.9492) 최고, MLP(0.9049)는 나이브(0.9224)보다 낮음.

그림 7에서 전체 모델의 R²를 한눈에 비교할 수 있다. 파란색 막대인 ML 모델 3종(LinearReg, RandomForest, XGBoost)은 모두 나이브 Baseline(회색, 0.9224)을 상회하며, XGBoost가 0.9492로 가장 높다. 반면 MLP(주황색, 0.9049)는 나이브 Baseline보다 낮은 수치를 기록하였다. 그러나 이것이 MLP가 무의미하다는 뜻은 아니다. MLP는 하이퍼파라미터 탐색이나 아키텍처 최적화 없이 기본 구조만으로 실험하였으며, 더 많은 데이터와 추가 튜닝을 통해 성능 향상의 여지가 충분히 존재한다.

6. Analysis / Discussion

6.1 Feature Importance 분석



[그림 8] XGBoost Feature Importance Top 20. rank_lag1(0.40) 압도적 1위, loan_lag1(0.18), loan_mean(0.10) 순.

Feature Importance는 XGBoost 모델이 각 피처를 분기 결정에 얼마나 자주, 그리고 얼마나 효과적으로 활용하였는지를 수치화한 것이다. 값이 클수록 해당 피처가 예측에 더 많이 기여하였음을 의미한다.

순위	피처명	중요도(약)	해석
1위	rank_lag1	0.40	직전달 인기 순위 — 강한 자기상관 반영
2위	loan_lag1	0.18	직전달 대출 건수 — 단기 모멘텀
3위	loan_mean	0.10	6개월 평균 — 중기 트렌드
4위	loan_max	0.04	최대 대출 실적
5위	rank_lag5	0.03	5개월 전 순위 — 중장기 패턴
6~20위	female_ratio, loanCnt_total, is_vacation 등	-	인구통계·이용통계·시간 피처 기여

표를 보면 상위 5개 피처가 모두 lag/rank 계열 피처임을 알 수 있다. rank_lag1이 0.40으로 압도적 1위를 차지하였는데, 이는 직전달 인기 순위가 다음 달 대출 수요를 예측하는 데 가장 강력한 신호임을 의미한다. 직전달에 인기 있던 책은 다음 달에도 인기가 유지되는 강한 자기상관이 존재하는 것이다. loan_lag1(0.18)과 loan_mean(0.10)은 각각 직전달 실제 대출 건수와 6개월 평균 대출 건수로, 단기 모멘텀과 중기 트렌드를 반영한다. loan_max(0.04)와 rank_lag5(0.03)는 해당 도서의 최대 대출 실적과 5개월 전 순위로, 도서의 잠재적 인기도와 중장기 패턴을 포착한다.

6위 이하에서는 female_ratio, loanCnt_total, is_vacation 등 인구통계·이용통계·시간 피처들이 Top 20에 포함되었다. 중요도 수치는 작지만 이 피처들이 모델 학습에 실제로 활용되고 있다는 것은, 단순 lag/rank 피처만으로는 설명

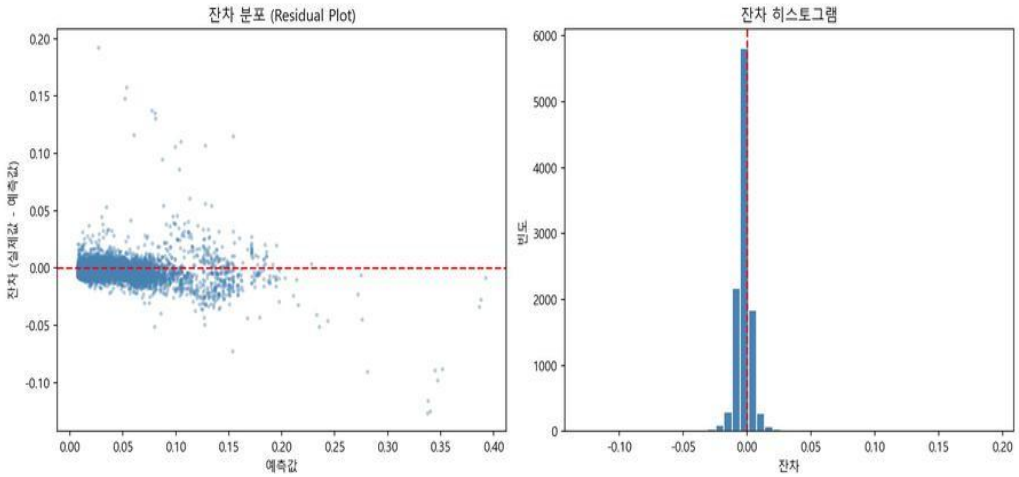
되지 않는 추가적인 패턴을 보완하고 있음을 시사한다. 특히 is_vacation(방학 여부)이 Top 20에 포함된 것은 방학 시즌의 도서 대출 패턴 변화가 예측에 의미 있는 신호를 제공함을 보여준다.

누수 피처 검증: ranking_trend, ranking_mean, loanCnt_total 제거 후 R^2=0.9491 (ΔR^2=-0.0001). 실질적 누수 영향 없음 확인.

6.2 과적합 분석

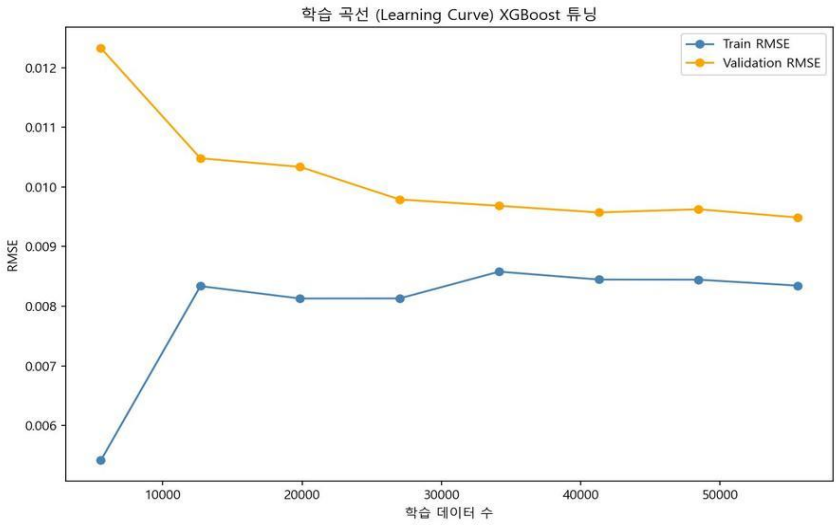
모델	Train R^2	Val R^2	Test R^2	Train-Test Gap
XGBoost tuned	0.9562	0.9547	0.9492	0.0070 (정상 범위)

Train R^2=0.9562, Validation R^2=0.9547, Test R^2=0.9492로 세 구간에서 성능이 일관되게 유지되고 있으며, Train-Test gap이 0.007로 매우 작다. 일반적으로 gap이 0.05 이하이면 과적합이 없는 것으로 판단하므로, 본 모델은 학습 데이터에 지나치게 맞춰지지 않고 새로운 데이터에도 잘 일반화됨을 확인하였다.



[그림 9] 잔차 분포 (XGBoost 튜닝, Test 셋). 좌: 0 중심 대칭 분포로 체계적 편향 없음. 우: 0 근처에 집중된 정규분포 형태.

그림 9의 왼쪽 잔차 분포를 보면 점들이 예측값 전 구간에 걸쳐 0을 중심으로 고르게 분포하고 있어 특정 구간에서 일관되게 과대 또는 과소 예측하는 체계적 편향이 없음을 알 수 있다. 오른쪽 잔차 히스토그램은 0 근처에 집중된 정규분포에 가까운 형태를 보이며, 이는 좋은 회귀 모델이 갖춰야 할 조건을 충족한다. 다만 예측값이 0.2 이상인 고대출 구간에서 잔차가 위쪽으로 퍼지는 경향이 보이는데, 이는 수요가 급격히 증가하는 도서에 대한 예측 오차가 상대적으로 크다는 것을 의미한다.



[그림 10] 학습 곡선 (XGBoost 튜닝). Train/Val RMSE 수렴, 과적합 없음.

그림 10의 학습 곡선에서 Train RMSE(파란선)는 학습 데이터 수가 적을 때 낮다가 데이터가 늘어남에 따라 점차 안정화되고, Validation RMSE(주황선)는 초반에 높다가 데이터가 증가할수록 지속적으로 감소하는 패턴을 보인다. 두 선이 수렴하며 일정 간격을 유지하고 있어 과적합이 없음을 확인할 수 있다. 또한 Validation RMSE가 데이터가 늘어날수록 계속 감소하는 추세를 보이는 것은 현재 학습 데이터가 충분히 포화 상태에 이르지 않았음을 의미한다. 즉 더 많은 데이터를 확보한다면 추가적인 성능 향상이 가능함을 시사한다.

6.3 결과 해석 및 핵심 결론

- R^2=0.95 의 의미: 높은 R^2는 데이터의 강한 월별 자기상관이 주 원인. 나이브도 R^2=0.9224 를 달성하므로, 모델 기여는 나이브 대비 MAE 13.2 건 개선으로 해석해야 함.
- PoC 검증 완료: 모델 B 가 모델 A 대비 RMSE 24.5% 향상. TF-IDF×TextRank 트렌드 피처 유효성 확인.
- 트리 기반 vs MLP: 표 형식 데이터에서 XGBoost(0.9492) > MLP(0.9049). Chen & Guestrin(2016)[3]의 연구와 일치.
- MLP 성능: 나이브(0.9224)보다 낮은 0.9049 기록. 표 형식 데이터에서 트리 모델이 일반적으로 우수하고, 83,372 행이 딥러닝에 다소 적을 수 있으며, 추가 튜닝 없이 기본 구조를 사용한 것이 원인으로 분석됨.

6.4 한계점 및 개선 방향

(1) 데이터 한계

- 전체 12,821 개 ISBN 중 1,030 개(8.0%)만 상세 데이터 확보. 나머지의 NLP·인구통계·co-loan 피처는 기본값(0) 처리. → 전체 ISBN 재수집 후 NLP 피처 기여도 재검증 필요
- 수집 기간 3 개년으로 제한. → 장기 시계열 확보 시 패턴 학습 개선 기대

(2) 모델 한계

- 하이퍼파라미터 튜닝이 4 가지 수동 조합에 그침. → Grid Search, Bayesian Optimization 적용 시 추가 향상 기대
- 신간 도서 Cold Start Problem 미해결. → 내용 기반 피처 보강 필요
- MLP 아키텍처 최적화 미실시. → 더 깊은 구조, 학습률 스케줄링으로 개선 가능

(3) 해석 한계

- NLP 피처의 실제 기여도는 전체 ISBN 재수집 후 ablation 실험으로 재검증 필요
- demand_score 타겟이 rank_gain 과 loan_ratio 의 결합이므로 실제 건수 예측과 미세한 차이 있음

7. Conclusion

7.1 전체 프로젝트 요약

성과 항목	결과
데이터 규모	104,572행 × 62개 피처, NaN 없음
ISBN 커버리지	66개 → 1,030개 (재수집으로 15.6배 확대)
PoC 검증	모델 B가 A 대비 RMSE 24.5% 향상, 트렌드 피처 유효성 확인
나이브 대비 개선	XGBoost: MAE 55.1건 → 41.9건 (-13.2건)
최고 성능 모델	XGBoost tuned: Test R^2=0.9297, RMSE=0.0086
딥러닝 MLP	R^2=0.9049 (TensorFlow + Google Colab)
과적합	없음 (Train-Test gap=0.007)

본 프로젝트는 도서관정보나루 공개 API 를 활용하여 다음 달 도서 대출 수요를 예측하는 머신러닝 파이프라인을 설계하고, 그 과정에서 발생한 기술적 난관을 직접 해결해나간 실험적 연구이다.

프로젝트 초기 가장 큰 문제는 데이터 수집 품질이었다. usageAnalysisList API 에서 수집된 유효 ISBN 이 단 66 개에 불과하였는데, 이는 API 가 빈 응답을 반환할 때 수집 코드가 이를 성공으로 처리하는 버그에서 비롯된 것이었다. 결과적으로 NLP 트렌드 피처, 이용자 인구통계 피처, co-loan 피처 대부분이 기본값인 0 으로 채워진 상태였고, 실질적으로는 lag/rank 기반 피처만으로 모델이 학습되고 있었다.

이를 해결하기 위해 dataset.py 의 수집 로직을 전면 수정하여 빈 응답을 실패로 처리하도록 개선하고, API rate limit 을 고려하여 여러 차례에 걸쳐 재수집을 진행하였다. 그 결과 유효 ISBN 수가 66 개에서 1,030 개로 약 15.6 배 확대되었다. 이는 단순한 수량 증가 이상의 의미를 가진다. 1,030 개 ISBN 에 대해 월별 대출 이력, 도서 키워드, 이용자 연령·성별 분포, 동시 대출 도서 정보가 함께 수집됨으로써, 기존에 0 으로 채워지던 피처들이 실제 값을 갖게 되었고 모델이 더 풍부한 정보를 학습할 수 있는 환경이 마련되었다.

재수집 이후 모델 성능 변화를 살펴보면, Lag 피처만 사용한 모델 A 에서는 최고 성능이 RandomForest R^2=0.9299 였던 반면, 전체 62 개 피처를 사용한 모델 B 에서는 RandomForest R^2=0.9605 로 향상되었다. Best RMSE 기준으로는 0.0098 에서 0.0074 로 약 24.5% 개선되었다. 이는 TF-IDF × TextRank 트렌드 유사도, 이용자 인구통계 집중도, co-loan 세그먼트 등 피처 엔지니어링의 결과가 실제로 예측 성능 향상에 기여하였음을 의미한다.

또한 나이브 Baseline 과의 비교를 통해 머신러닝 모델의 실질적 기여를 확인하였다. "지난달 대출 수 = 다음 달 대출 수"라는 단순한 방법만으로도 R^2=0.9224 가 달성되는 것은 도서 대출 데이터의 강한 월별 자기상관 특성을 보여준다. 이러한 배경에서 XGBoost tuned 모델이 MAE 를 55.1 건에서 41.9 건으로 13.2 건 개선한 것은 단순 반복 예측을 넘어 실질적인 예측 정확도를 높였음을 의미한다.

7.2 모델별 의미 요약

실험에 사용된 네 가지 모델은 각각 고유한 역할을 담당하였다.

LinearRegression 은 Baseline 으로서 데이터의 선형성을 확인하는 역할을 하였다. 모델 B 기준 R^2=0.9497 을 기록하며 도서 대출 수요의 상당 부분이 직전달 대출량과 선형 관계로 설명 가능함을 보였다. 그러나 급상승 도서처럼 비선형적으로 수요가 변하는 패턴은 포착하지 못한다는 한계를 확인하였다.

RandomForest 는 비선형 패턴 학습과 Feature Importance 분석이라는 두 가지 역할을 동시에 수행하였다. Validation 기준 R^2=0.9605 로 머신러닝 모델 중 최고 성능을 기록하였으며, Feature Importance 분석을 통해 rank_lag1 이 가장 중요한 피처임을 확인하였다. 이는 직전달 인기 순위가 다음 달 대출 수요를 가장 강하게 반영한다는 의미이다.

XGBoost 는 하이퍼파라미터 튜닝을 통해 Validation R^2=0.9600, Test R^2=0.9297, 나이브 대비 MAE 13.2 건 개선으로 최종 Test 기준 머신러닝 모델 중 최고 성능을 달성하였다. 이전 트리의 오차를 순차적으로 보완하는 Gradient Boosting 구조가 도서 대출의 복잡한 패턴 학습에 효과적이었음을 확인하였다.

MLP 딥러닝 모델은 선택 과제로 TensorFlow 를 활용하여 Google Colab 에서 구현하였다. R^2=0.9049 를 달성하였으며, XGBoost 보다 낮은 성능을 보인 것은 표 형식 데이터에서 트리 기반 모델이 딥러닝보다 일반적으로 우수하다는 선행 연구의 결과와 일치한다. 그럼에도 딥러닝 구조가 이 예측 과제에 적용 가능함을 확인하였으며, 더 많은 데이터와 추가적인 아키텍처 최적화를 통해 성능 향상의 여지가 있음을 시사한다.

7.3 예측 가능성 및 실용적 의미

본 프로젝트의 결과를 통해 확인할 수 있었던 것은 다음과 같다. 도서 대출 수요는 월별 자기상관이 강하여 단순 패턴만으로도 높은 예측 가능성을 가진다. 여기에 트렌드 키워드 유사도, 이용자 인구통계, co-loan 피처를 추가함으로써 더 정밀한 예측이 가능해진다. 구체적으로는 직전달 인기 순위와 대출 이력을 기반으로 다음 달 대출 수요가 높을 도서를 미리 식별할 수 있으며, 방학·학기 시작 등 시간적 패턴과 트렌드 키워드와의 연관성을 반영하여 계절별·이슈별 수요 급증 도서를 사전에 탐지할 수 있다. 이는 도서관의 장서 구매 계획 수립, 인기 급상승 도서의 조기 입고, 계절별 맞춤형 전시 추천 등에 실질적으로 활용될 수 있다.

다만 현재 결과는 PoC 수준으로 해석하는 것이 적절하다. 전체 12,821 개 ISBN 중 1,030 개만 상세 데이터를 확보하였으므로, 전체 ISBN 재수집이 완료된 이후 NLP 피처와 인구통계 피처의 실질적 기여도를 재검증하는 것이 필요하다. 이후 단계에서 추가 성능 향상이 기대된다.

또한, 각 팀원들의 본 학과별 의의를 찾아보면 다음과 같다.

우선, 경영학적 관점에서 본 프로젝트는 도서관 운영을 경험적 판단 중심에서 데이터 기반 의사결정 체계로 전환할 가능성을 보여준다. 모델 B 가 모델 A 보다 우수한 성능을 보인 것은 과거 대출량뿐 아니라 트렌드 키워드, 도서 메타정보, 이용자 통계, 동시 대출 정보가 수요 예측에 추가적인 가치를 제공함을 의미한다. 이를 활용하면 도서관은 다음 달 수요가 높을 것으로 예상되는 도서를 사전에 파악하여 복본 구매, 예약 대기 관리, 추천 도서 선정, 북큐레이션 기획 등에 활용할 수 있다. 향후에는 더 많은 ISBN 과 장기 시계열 데이터를 확보하고, 예측 결과를 대시보드나 추천 시스템과 연계하여 장서 구매·배치·프로그램 기획을 지원하는 운영관리 시스템으로 발전시킬 수 있다.

다만 예측 결과는 자동화된 최종 결정 기준이 아니라 사서의 전문적 판단을 보조하는 참고 지표로 활용되는 것이 바람직하다.

행정학적 관점에서 본 프로젝트는 공공 도서관은 시민의 지식 접근권을 보장하는 핵심 공공서비스 기관으로, 현재 대부분의 운영 방식은 사서의 경험적 판단과 단순 통계에 의존하고 있다. 본 프로젝트는 공공데이터 포털의

도서관정보나루 빅데이터를 활용하여 수요를 정량적으로 예측함으로써 데이터 기반 행정의 가능성을 열었다는 점에서 의의가 있다. 실제로 장서 구매, 폐기 계획 등 도서관 운영의 핵심 의사결정에 이 시스템이 보조 도구로 활용된다면 예산 효율성과 서비스 품질을 동시에 높일 수 있다.

다만 알고리즘 기반 의사결정은 효율성을 높이는 동시에 형평성 문제를 야기할 수 있다는 문제점도 제기된다. 대출 수요 예측 점수가 낮다는 이유로 소수 언어 도서, 향토 자료, 장애인 대상 도서 등 대출은 적지만 공공적 가치가 높은 자료가 배제될 위험이 있으며, 이는 사회적 형평성과 충돌될 수 있다는 우려도 존재한다. 따라서 이 시스템은 최종 의사결정의 도구가 아닌 사서의 판단을 보완하는 참고 자료이자 보조도구로 활용되어야 하며, 도입 시 공공 거버넌스 차원의 충분한 논의가 선행되어야 한다.

7.4 윤리·공정성 논의

(1) 의사결정 공정성

모델 예측값을 도서 폐기·구매 의사결정에 직접 사용 시 소수 언어 도서·희귀본·지역 향토 자료가 불이익을 받을 수 있다. 모델 예측값은 참고 자료로만 활용하고 최종 판단은 사서의 전문적 식견과 결합해야 한다.

(2) 인기 도서 편향 (Popularity Bias)

과거 이력이 풍부한 도서에 더 정확한 예측을 제공하므로 신간·비주류 도서가 불이익을 받을 수 있다. 추천 시스템에 다양성(Diversity) 지표를 함께 적용하는 것을 권장한다.

(3) 개인정보 보호

활용한 인구통계 데이터는 집계 통계 형태로 개인 식별이 불가능하며, 개별 이용자의 대출 기록은 전혀 사용하지 않았다.

7.5 기대 효과 및 향후 확장

- 단기: 전체 ISBN 재수집 후 NLP·인구통계·co-loan 피처 기여도 재검증
- 중기: Grid Search/Bayesian Optimization, MLP 아키텍처 고도화
- 장기: 온라인 학습으로 실시간 트렌드 반영, 도서관 실무 시스템 연동
- 응용: 장서 구매 계획 지원, 인기 급상승 도서 조기 감지, 계절별 맞춤형 전시 추천

References

[1] Koren, Y., Bell, R., & Volinsky, C. (2009). Matrix Factorization Techniques for Recommender Systems. IEEE Computer, 42(8), 30-37.

[2] Makridakis, S., Spiliotis, E., & Assimakopoulos, V. (2018). Statistical and Machine Learning forecasting methods: Concerns and ways forward. PLOS ONE, 13(3).

[3] Chen, T., & Guestrin, C. (2016). XGBoost: A Scalable Tree Boosting System. Proceedings of the 22nd ACM SIGKDD, 785-794.

[4] Mihalcea, R., & Tarau, P. (2004). TextRank: Bringing Order into Text. Proceedings of EMNLP 2004, 404-411.

[5] Salton, G., & Buckley, C. (1988). Term-weighting approaches in automatic text retrieval. Information Processing & Management, 24(5), 513-523.

[6] 도서관정보나루 빅데이터 분석 공모전 우수작 (2023). 도서 대출 패턴 분석 및 수요 예측 모델 개발.

[7] 도서관정보나루. (2026). 공공도서관 빅데이터 API 서비스. https://www.data4library.kr/

[8] Goodfellow, I., Bengio, Y., & Courville, A. (2016). Deep Learning. MIT Press.

[9] Abadi, M., et al. (2016). TensorFlow: A System for Large-Scale Machine Learning. OSDI, 265-283.